


FT108A – Introdução ao Aprendizado de Máquina (2s2026)


Lista de Exercícios
Classificação de Dados

Questões:

- 1) Considerando uma tarefa de predição de dados, realizada via aprendizado supervisionado, na Figura 1 são apresentados os resultados obtidos por dois modelos (linhas tracejadas), treinados com as amostras indicadas por '+'. Sabendo que a função real do problema é dada pela linha contínua, indique o tipo de erro predominante no resultado da Figura 1(a) e no da Figura 1(b). Indique também, para cada caso, medidas que poderiam ser tomadas para melhorar os resultados.



(a)



(b)

Figura 1 - Exemplo de aproximação de funções via aprendizado supervisionado. Os símbolos de '+' correspondem às amostras de treinamento, as curvas contínuas à função real e as curvas tracejadas aos modelos obtidos.

- 2) A base de dados apresentada na Tabela 1 contém amostras de dados de 14 pessoas avaliadas em uma clínica. Cada amostra desta base, que pode ser de um paciente doente ou não (classes C_i do problema), possui quatro atributos: todos já discretizados por especialistas. Suponha que um novo paciente **jovem** (x) chegue na clínica apresentando nível **médio da substância A** no sangue, nível **baixo da substância B** no sangue e **possua histórico familiar** da doença. A qual classe do problema um classificador *Naïve Bayes* atribuiria o paciente x ? Apresente **todos** os cálculos realizados para chegar à sua conclusão.
- 3) Ainda considerando a base de dados dada na Tabela 1, qual atributo seria selecionado pelo critério de **Ganho de Informação** para realizar o primeiro particionamento da base, em um processo de indução de árvore de decisão? Apresente todos os cálculos realizados para chegar à sua conclusão.
- 4) Na Figura 2 é dada uma árvore de decisão para o problema de classificação de pacientes cujos dados estão na Tabela 1. A partir desta árvore e dos dados contidos na Tabela 1, pede-se:
- Aplique a árvore de decisão da Figura 2 a **todas as amostras** contidas na Tabela 1 e apresente as classes preditas.
 - Apresente a matriz de confusão gerada pela árvore quando aplicada aos dados da Tabela 1.
 - Calcule a acurácia da árvore de decisão para o conjunto de dados apresentado na Tabela 1. A partir do valor calculado, pode-se dizer que a árvore de decisão da Figura 2 é um bom classificador? Discuta.

Tabela 1 - Base de dados sobre pacientes de uma clínica.

ID	Idade	Nível da substância A no sangue	Nível da substância B no sangue	Histórico na Família	Está doente
1	Jovem	Alto	Baixo	Não	Não
2	Jovem	Alto	Alto	Não	Não
3	Adulto	Alto	Baixo	Não	Não
4	Idoso	Médio	Baixo	Não	Não
5	Idoso	Baixo	Baixo	Sim	Não
6	Idoso	Baixo	Alto	Sim	Não
7	Adulto	Baixo	Alto	Sim	Não
8	Jovem	Médio	Baixo	Não	Não
9	Jovem	Baixo	Baixo	Sim	Sim
10	Idoso	Médio	Baixo	Sim	Não
11	Jovem	Médio	Alto	Sim	Não
12	Adulto	Médio	Alto	Não	Não
13	Adulto	Alto	Baixo	Sim	Não
14	Idoso	Médio	Alto	Não	Sim




Figura 2 - Árvore de Decisão para classificação de pacientes.

- 5) Qual a finalidade do processo de poda em árvores de decisão? Como ele pode ser implantado?
- 6) Uma das etapas de pré-processamento de dados recomendada, sempre que o algoritmo *k*-NN é aplicado a bases de dados com atributos contínuos, é a normalização dos dados. Dito isso, pede-se:
- Explique em que situações a normalização é importante e como sua não-realização pode impactar nos resultados da classificação.
 - Crie um pequeno exemplo de base de dados que ilustre a explicação dada na resposta anterior.
- 7) Em uma base de dados **similar** à da Tabela 1, mas com os atributos *idade do paciente* sendo um valor numérico, *nível de duas substâncias A e B no sangue* também valores numéricos, e a presença ou não de *histórico da doença na família* um valor binário, responda:
- Considerando-se a utilização de uma rede neural do tipo **Perceptron Multicamadas** (MLP) como classificador de dados, supondo que sejam adotados **10 (dez) neurônios** na **única camada oculta** da rede e que **todos os neurônios tenham *bias***, indique o **número total de entradas e de saídas** que você definiria para esta rede e calcule o **número total de pesos** a serem ajustados durante a etapa de treinamento.
 - Ao treinar a MLP indicada no item (a) você observou que, apesar da rede apresentar uma acurácia de 98% para os dados de treinamento, sua taxa de acertos cai para menos de 60% para os dados de teste. Diante disso pergunta-se: o que poderia estar acontecendo? Que medidas você adotaria para tentar sanar este problema?
 - Considerando os atributos da base de dados descritos no enunciado e seu conhecimento sobre MLPs, quais **etapas de pré-processamento** você aplicaria neste cenário?
- 8) A base de dados apresentada na Tabela 2 contém 14 amostras associadas a um problema de classificação. Na Tabela 2 são apresentados também os rótulos reais de cada amostra e os rótulos atribuídos por três classificadores. Neste contexto, pede-se:
- Apresente os rótulos que seriam atribuídos a cada amostra dos dados por um *ensemble*, baseado em **voto majoritário**, formado pelos três classificadores cujas saídas foram apresentadas;
 - Apresente as matrizes de confusão construídas a partir dos resultados de cada classificador e do *ensemble*, em conjunto com as respectivas acurácias;
 - Compare e discuta os resultados.

Tabela 2 - Base de dados para outro problema de classificação de dados.

ID	Classe Real	Classificador 1	Classificador 2	Classificador 3	Ensemble
1	A	A	B	A	
2	A	B	A	A	
3	B	A	B	A	
4	B	B	B	A	
5	B	A	B	B	
6	A	B	B	B	
7	B	B	B	B	
8	A	A	A	A	
9	A	A	B	A	
10	B	B	B	A	
11	A	A	A	B	
12	B	B	B	B	
13	B	B	B	A	
14	A	A	B	B	